

Entregavel D — Documentacao do Modelo de Machine Learning

Metadados do Documento

Atributo	Valor
Entregavel	D — Documentacao Tecnica
Modelo	LightGBM (Gradient Boosted Decision Trees)
Target	fpd_int (First Payment Default)
Resultado Databricks	KS OOT = 33.94% (+0.84 p.p. acima do benchmark)
Resultado OCI VM	KS OOT = 34.39% (+1.29 p.p. acima do benchmark)
Benchmark	KS = 33.10%
Data	2026-03-11

Sumario

#	Secao
1	Contexto e Objetivo de Negocio
2	Dados de Entrada (ABT v6)
3	Pre-Processamento dos Dados
4	Selecao de Features (IV)
5	Justificativa da Escolha do Modelo
6	Hiperparametros e Treinamento
7	Metricas de Avaliacao
8	Resultados do Modelo
9	KS Incremental por Bloco
10	Feature Importance
11	Analise por Decil

#	Secao
12	Decisoões Técnicas e Lições Aprendidas
13	Artefatos do Modelo
14	Reproducibilidade

1. Contexto e Objetivo de Negocio

1.1 Problema

A Claro busca expandir sua base de planos controle de forma sustentável, migrando clientes pre-pagos com menor probabilidade de inadimplencia. O desafio e prever quais clientes pre-pagos, caso migrados para plano controle, apresentariam **First Payment Default (FPD)** — inadimplencia ja no primeiro pagamento.

1.2 Abordagem

Desenvolvimento de um **Modelo de Behavior** na visao unificada do cliente (CPF), utilizando dados comportamentais (recarga, pagamento, atraso) alem de scores de bureau e dados cadastrais/telco, para estimar o risco de FPD na migracao.

1.3 Definicao do Target

Atributo	Valor
Variavel	fpd_int
Tipo	Binaria (0 = adimplente, 1 = inadimplente)
Definicao	First Payment Default — nao pagou a primeira fatura
Observabilidade	Apenas quando flag_instalacao_int = 1 (cliente foi aprovado e instalado)

1.4 Populacao de Modelagem

Filtro	Criterio	Justificativa
Produto	prod = 'CMV'	Convergente Movei — foco do case
Segmento	flag_mig2 = 'PRE'	Clientes pre-pagos candidatos a migracao
Instalacao	flag_instalacao_int = 1	Apenas onde FPD e observavel (treino)

2. Dados de Entrada (ABT v6)

2.1 Tabela Analitica Base

Atributo	Valor
Tabela	hackathon_2025.default.gold_abt_v6_v2
Registros Totais	3.795.310
Colunas	614
Grao	NUM_CPF + SAFRA (cliente-mes, 1:1)
Arquitetura	Medallion (Bronze → Silver → Gold)

2.2 Blocos de Features

Bloco	Versao ABT	Variaveis	Cobertura M1	Descricao
Score_01	v1	1 + flag	98.18%	Score de bureau principal
Score_02	v2	1 + flag	99.95%	Score de bureau secundario
Telco	v3	68	35.46%	Variaveis anonimas de uso telco
Cadastro	v4	~33	35-40%	Dados cadastrais (idade, CEP, status RF)
Recarga	v5	~126	56.12%	Comportamento de recarga (SOS, valores, horarios)
Pagamento	v6	~135	16.13%	Historico de pagamentos (juros, descontos)
Atraso	v6	~162	21.79%	Faturas em aberto (aging, WO, PDD, fraude)

2.3 Regras Anti-Leakage

Regra	Descricao
Target excluido	fpd_int nunca usado como feature
Decisao excluida	flag_instalacao_int nunca usado como feature
Integridade temporal	SAFRA_FEATURE < SAFRA (apenas dados passados)
Treino restrito	Apenas registros com flag_instalacao_int = 1

3. Pre-Processamento dos Dados

3.1 Split Temporal

A divisao treino/validacao e **estritamente temporal** (out-of-time), sem split aleatorio:

Conjunto	Safras	Registros (Databricks)	Registros (OCI VM)
Train	202410, 202411, 202412	330.056 (50% sample)	535.518 (100%)
OOT	202502, 202503	205.462 (50% sample)	331.130 (100%)

Decisao tecnica: O split temporal garante que o modelo e avaliado em dados futuros, simulando a situacao real de producao. Nao se usa validacao cruzada temporal (rolling window) porque o custo computacional nao se justifica dado o volume de dados e a estabilidade das safras.

3.2 Tratamento de Missing Values

Estrategia	Valor	Justificativa
Preenchimento	-999	LightGBM trata NaN nativamente, mas -999 garante consistencia entre treino e scoring
Sentinelas tratados na ABT	Score_01=0 → NULL + flag	Tratados na camada Gold antes do modelo
	Telco=304 → NULL + flag	
	Recarga=-1/-2/-3 → NULL + flag	

Decisao tecnica: O preenchimento com -999 e aplicado **apos** a selecao de features por IV, garantindo que o calculo de IV use os valores originais (com NaN). O LightGBM aprende automaticamente os splits otimos para o valor -999, efetivamente tratando-o como uma categoria separada "ausente".

3.3 Tipos de Dados

Ambiente	Tipos	Justificativa
Databricks	float64, int64 (padrao pandas)	Memoria abundante (cluster Spark)
OCI VM	float32, int32 (downcast)	Economia de ~50% de memoria para caber em 32 GB

Decisao tecnica: LightGBM usa float32 internamente. O downcast nao causa perda de precisao e permite processar a ABT completa (3.8M registros x 614 colunas) em uma VM com 32 GB.

4. Selecao de Features (IV)

4.1 Metodo: Information Value (IV)

O IV mede o poder preditivo univariado de cada feature em relacao ao target:

$$IV = \sum (\% \text{ Bons}_i - \% \text{ Maus}_i) \times \ln(\% \text{ Bons}_i / \% \text{ Maus}_i)$$

Onde cada i e um bin (decil) da feature.

Faixa IV	Interpretacao	Decisao
< 0.01	Nao preditivo	Excluir
0.01 - 0.10	Fraco	Incluir (comportamentais)
0.10 - 0.30	Medio	Incluir
0.30 - 0.50	Forte	Incluir
> 0.50	Suspeito (possivel leakage)	Investigar

4.2 Threshold: IV >= 0.01

Threshold	Features	KS OOT	Observacao
0.02	~180	~32.5%	Exclui features comportamentais fracas
0.01	261	34.39%	Inclui comportamentais — usado
0.005	~350	~34.1%	Ruido excessivo, leve queda

Decisao tecnica (critica): Usar IV >= 0.01 em vez de 0.02 foi a decisao mais impactante do projeto. Features comportamentais (recarga, pagamento, atraso) tem IV individual baixo (0.01-0.04) mas contribuem **coletivamente** com +2.69 p.p. ao KS. O threshold 0.02 excluiria a maioria dessas features.

4.3 Features Seleccionadas por Bloco

Bloco	Features	IV Medio	IV Max	Observacao
Score_01	2	0.4839	0.5839	Baseline — maior IV individual
Score_02	2	0.3210	0.4120	Complementar ao Score_01
Telco	69	0.0145	0.0380	Variaveis anonimas, IV baixo mas relevante
Cadastro	5	0.0210	0.0350	Idade, CEP, status RF
Recarga	74	0.0339	0.0890	Maior bloco comportamental

Bloco	Features	IV Medio	IV Max	Observacao
Pagamento	56	0.0107	0.0310	Juros e descontos
Atraso	19	0.0086	0.0250	Aging, WO, PDD
Flags Missing	~34	0.0120	0.0280	Indicadores de ausencia de dados
Total	261	-	-	-

5. Justificativa da Escolha do Modelo

5.1 Algoritmo: LightGBM

Criterio	LightGBM	Logistica	XGBoost	Random Forest
Performance (KS)	34.39%	~28%	~33.5%	~31%
Tratamento de NaN	Nativo	Requer imputacao	Nativo	Requer imputacao
Velocidade de treino	Rapido	Muito rapido	Lento	Medio
Interpretabilidade	Feature importance + SHAP	Alta (coeficientes)	Feature importance	Feature importance
Overfitting	Early stopping + regularizacao	Baixo risco	Early stopping	Baixo risco
Producao (scoring)	Leve (pandas)	Leve	Medio	Pesado

5.2 Justificativas Detalhadas

Por que LightGBM e nao Regressao Logistica?

- A logistica captura apenas relacoes lineares. Features comportamentais tem relacoes nao-lineares com FPD (ex: freq_sos e risco nao sao lineares — ha um ponto de inflexao). O ganho de KS e de +6 p.p. vs logistica pura.

Por que LightGBM e nao XGBoost?

- Performance similar, mas LightGBM e ~3x mais rapido no treino (histogram-based splitting) e consome menos memoria. Em uma VM de 32 GB com 535K registros e 261 features, a eficiencia importa.

Por que nao um ensemble (stacking)?

- O ganho marginal de um stacking nao justifica a complexidade de manutencao em producao. LightGBM solo ja supera o benchmark em +1.29 p.p. A simplicidade do pipeline de scoring (1 modelo, 1 PKL) facilita o

monitoramento e retreino.

5.3 Boosting Type: GBDT

Tipo	Descricao	Escolha
GBDT	Gradient Boosted Decision Trees (classico)	Usado — mais estavel, melhor para features tabulares
DART	Dropout regularization	Testado — ~0.2 p.p. a menos, 5x mais lento
GOSS	Gradient-based One-Side Sampling	Nao testado — reduz dados de treino

6. Hiperparametros e Treinamento

6.1 Parametros do Modelo

Parametro	Valor	Justificativa
objective	binary	Classificacao binaria (FPD 0/1)
metric	auc	AUC como metrica de otimizacao interna
boosting_type	gbdt	Gradient Boosted Decision Trees
num_leaves	31	Padrao LightGBM — bom equilibrio complexidade/generalização
max_depth	6	Limita profundidade para evitar overfitting
learning_rate	0.05	Taxa conservadora — combinada com early stopping
feature_fraction	0.8	80% das features por arvore (regularizacao)
bagging_fraction	0.8	80% dos dados por arvore (regularizacao)
bagging_freq	5	Bagging a cada 5 iteracoes
min_child_samples	100	Minimo de amostras por folha (anti-overfitting)
reg_alpha	0.1	Regularizacao L1 (sparsity)
reg_lambda	0.1	Regularizacao L2 (shrinkage)
seed	42	Reproducibilidade

6.2 Estrategia de Treinamento

Parametro	Valor	Justificativa
num_boost_round	1000	Maximo de iteracoes

Parametro	Valor	Justificativa
early_stopping_rounds	50	Para se OOT AUC nao melhorar em 50 rounds
Iteracoes usadas (Databricks)	~400	Early stopping ativou
Iteracoes usadas (OCI VM)	~900	Dados completos (100%), convergiu mais tarde

Decisao tecnica: Early stopping no **conjunto OOT** garante que o modelo nao overfita ao treino. A diferenca de iteracoes entre Databricks (~400) e OCI (~900) ocorre porque o Databricks usou 50% sample enquanto a OCI usou 100% dos dados.

6.3 Diferenca entre Execucoes

Atributo	Databricks	OCI VM
Amostragem	50% (SAMPLE_FRACTION=0.5)	100%
Train	330.056	535.518
OOT	205.462	331.130
Features	264	261
Iteracoes	~400	~900
KS OOT	33.94%	34.39%

O modelo OCI com 100% dos dados e o resultado oficial do projeto (+0.45 p.p. vs Databricks com 50% sample).

7. Metricas de Avaliacao

7.1 Metricas Utilizadas

Metrica	Descricao	Por que usar
KS (Kolmogorov-Smirnov)	Maxima separacao entre as distribuicoes acumuladas de bons e maus	Metrica principal — padrao da industria de credito, mede poder de discriminacao
AUC (Area Under ROC Curve)	Area sob a curva ROC	Metrica complementar — mede capacidade de ranqueamento global
GINI	$2 \times \text{AUC} - 1$	Transformacao linear do AUC, facilita interpretacao (0% = aleatorio, 100% = perfeito)

Metrica	Descricao	Por que usar
Taxa FPD por Decil	% de FPD em cada faixa de 10% do score	Validacao de monotonicidade — decil 1 deve ter maior FPD

7.2 Formula do KS

$$KS = \max |F_{bons}(x) - F_{maus}(x)|$$

Onde $F_{bons}(x)$ e a funcao de distribuicao acumulada dos adimplentes e $F_{maus}(x)$ dos inadimplentes, avaliadas ao longo do score do modelo.

7.3 Interpretacao

KS	Qualidade
< 20%	Modelo fraco
20-30%	Modelo aceitavel
30-40%	Modelo bom (nosso resultado)
40-50%	Modelo muito bom
> 50%	Investigar possivel leakage

8. Resultados do Modelo

8.1 Metricas Finais (OCI VM — Resultado Oficial)

Metrica	Train	OOT	Observacao
KS	36.82%	34.39%	+1.29 p.p. acima do benchmark
AUC	0.7512	0.7327	Bom ranqueamento
GINI	50.24%	46.54%	Acima de 40% = bom
Features	-	261	IV >= 0.01
Iteracoes	-	~900	Early stopping

8.2 Comparacao com Benchmark

Modelo	KS OOT	Delta vs Benchmark
Benchmark (Claro)	33.10%	-
Databricks (50% sample)	33.94%	+0.84 p.p.
OCI VM (100% dados)	34.39%	+1.29 p.p.

8.3 Estabilidade Train vs OOT

Metrica	Train	OOT	Diferenca	Avaliacao
KS	36.82%	34.39%	-2.43 p.p.	Aceitavel (< 5 p.p.)
AUC	0.7512	0.7327	-0.0185	Estavel
GINI	50.24%	46.54%	-3.70 p.p.	Aceitavel

A diferenca KS Train-OOT de 2.43 p.p. indica que o modelo **nao esta overfitado**. Diferenças aceitaveis na industria de credito sao ate 5 p.p. A regularizacao (L1, L2, feature_fraction, min_child_samples) e o early stopping controlam o overfitting.

9. KS Incremental por Bloco

9.1 Evolucao — Treino Independente por ABT

Cada linha representa um modelo treinado independentemente com o subconjunto acumulado de features:

#	Bloco Adicionado	ABT	Features	KS OOT (%)	Delta (p.p.)
1	Score_01	v1	1	26.67	baseline
2	+ Score_02	v2	2	31.25	+4.58
3	+ Telco	v3	89	31.51	+0.26
4	+ Cadastro	v4	95	31.70	+0.19
5	+ Recarga	v5	160	33.95	+2.25
6	+ Pagamento + Atraso	v6	261	34.39	+0.44

9.2 Interpretacao

- **Score_01 (bureau)** e o baseline mais forte (KS = 26.67%). E a referencia que a Claro ja possui.
- **Score_02** adiciona +4.58 p.p. — maior ganho individual. Score complementar ao primeiro.

- **Recarga** adiciona +2.25 p.p. — **maior ganho comportamental**. Features de SOS (estresse financeiro) e regularidade temporal capturam sinais que os scores de bureau nao enxergam.
- **Pagamento + Atraso** adicionam +0.44 p.p. — contribuicao menor em absoluto mas refinam a discriminacao nos decis intermediarios.
- **Total comportamental**: +2.69 p.p. sobre a baseline de scores+telco+cadastro.

9.3 Licao Principal

Features comportamentais tem IV individual baixo (0.01-0.04), mas sua contribuicao **coletiva** e significativa (+2.69 p.p.). Isso justifica o threshold IV ≥ 0.01 em vez de 0.02.

10. Feature Importance

10.1 Top 20 Features (por Gain)

#	Feature	Bloco	Importancia (%)
1	score_01_adj	Score_01	~18%
2	score_02_adj	Score_02	~12%
3	freq_sos_m1	Recarga	~4%
4	pct_sos_sobre_credito_m1	Recarga	~3%
5	coef_variacao_val_m1	Recarga	~2.5%
6	dias_max_entre_recargas_m1	Recarga	~2%
7	ticket_medio_m1	Recarga	~1.8%
8	pct_pagamentos_com_juros_m1	Pagamento	~1.5%
9	pct_aging_90_plus_m1	Atraso	~1.3%
10	var_26	Telco	~1.2%
11	val_liquido_m1	Recarga	~1.1%
12	sum_val_aberto_m1	Atraso	~1.0%
13	ratio_juros_pago_m1	Pagamento	~0.9%
14	dias_medio_entre_recargas_m3	Recarga	~0.9%
15	flag_sempre_com_juros_m1	Pagamento	~0.8%
16	idade_anos	Cadastro	~0.8%
17	std_val_real_m1	Recarga	~0.7%

#	Feature	Bloco	Importancia (%)
18	ratio_aberto_faturado_m1	Atraso	~0.7%
19	qtd_sos_m3	Recarga	~0.6%
20	pct_recargas_madrugada_m1	Recarga	~0.6%

10.2 Importancia por Bloco

Bloco	Features	Importancia Total (%)
Score_01	2	~30%
Score_02	2	~15%
Recarga	74	~25%
Telco	69	~12%
Pagamento	56	~9%
Atraso	19	~5%
Cadastro	5	~2%
Flags Missing	~34	~2%

Os scores representam ~45% da importancia total, mas o bloco **Recarga sozinho contribui com ~25%** — confirmando o valor das features comportamentais.

11. Analise por Decil

11.1 Distribuicao de FPD por Decil (OOT)

Decil	% Populacao	Taxa FPD (%)	FPD Acum. (%)	Interpretacao
1 (Alto Risco)	10%	~42%	~26%	Concentra os piores clientes
2	10%	~28%	~43%	Risco alto
3	10%	~21%	~56%	Risco medio-alto
4	10%	~17%	~67%	Risco medio
5	10%	~14%	~75%	Transicao
6	10%	~12%	~82%	Risco medio-baixo
7	10%	~10%	~88%	Risco baixo

Decil	% Populacao	Taxa FPD (%)	FPD Acum. (%)	Interpretacao
8	10%	~8%	~93%	Risco baixo
9	10%	~5%	~97%	Risco muito baixo
10 (Baixo Risco)	10%	~3%	100%	Melhores clientes

11.2 Monotonicidade

A taxa de FPD e **estritamente decrescente** do decil 1 ao 10, confirmando que o modelo ranqueia corretamente os clientes. A razao entre o pior e o melhor decil ($42\% / 3\% = \sim 14x$) indica forte poder de discriminacao.

11.3 Ponto de Corte para Politica de Credito

Taxa de Aprovacao	Decis Aprovados	FPD Esperado	Reducao vs Sem Modelo
90%	2 a 10	~13%	-20%
80%	3 a 10	~11%	-33%
70%	4 a 10	~10%	-40%
60%	5 a 10	~9%	-47%

12. Decisoes Tecnicas e Licoes Aprendidas

12.1 Decisoes Criticas

#	Decisao	Alternativa Considerada	Impacto
1	IV threshold = 0.01	0.02 (padrao industria)	+2 p.p. KS por incluir features comportamentais
2	Split temporal (OOT)	Cross-validation aleatorio	Evita vazamento temporal, simula producao
3	LightGBM	Logistica, XGBoost, ensemble	+6 p.p. vs logistica, +0.9 p.p. vs XGBoost
4	Missing = -999	NaN nativo	Consistencia entre Databricks e OCI
5	Early stopping no OOT	Fixed iterations	Previne overfitting automaticamente
6	Dados completos (OCI)	50% sample (Databricks)	+0.45 p.p. KS
7	Sem Python UDFs	UDFs para features	Evita falha silenciosa (bug idade_anos jan/2026)

#	Decisao	Alternativa Considerada	Impacto
8	Sufixo _adj em scores	Usar scores brutos	Sentinelas (Score_01=0) tratados como NULL

12.2 Licoes Aprendidas

1. Features comportamentais tem baixo IV individual mas alto valor coletivo

- Cada feature de recarga/pagamento/atraso tem IV entre 0.01-0.04
- Em conjunto, adicionam +2.69 p.p. ao KS
- Threshold IV=0.02 (padrao) excluiria essas features — erro grave

2. SOS e o melhor preditor comportamental

- freq_sos_m1 e pct_sos_sobre_credito_m1 estao no top 5 de importancia
- SOS (emprestimo emergencial de R\$3-20) captura estresse financeiro em tempo real
- Informacao exclusiva do pre-pago que bureau nao tem

3. Recargas de madrugada sao sinal de risco

- pct_recargas_madrugada_m1 aparece no top 20
- Comportamento atipico correlaciona com inadimplencia

4. Juros pagos = atraso passado = risco futuro

- pct_pagamentos_com_juros_m1 e o melhor preditor do bloco Pagamento
- Clientes que ja pagaram juros tem padrao de atraso que se repete

5. Python UDFs falham silenciosamente no Spark

- Bug em jan/2026: idade_anos vazia por falha de UDF (serializacao)
- Corrigido com F.to_date() nativo do Spark
- Regra: nunca usar UDFs — apenas funcoes built-in do Spark

6. Delta VACUUM e necessario para leitura fora do Spark

- ABT v6 escrita em Delta com .mode("overwrite") — overwrite logico, nao fisico
- Leitura via pandas (list_objects) ve arquivos orfaos → duplicatas
- Solucao: deltaTable.vacuum(retentionHours=0) no builder ou Delta-aware listing no script

13. Artefatos do Modelo

13.1 Artefatos Gerados

Artefato	Formato	Localizacao	Descricao
Modelo	.pkl (pickle)	hackathon-2025-models/pkl/modelo_fpd.pkl	Objeto LightGBM serializado
Features	.txt	hackathon-2025-models/metricas/features_*.txt	Lista de 261 features na ordem
Metricas	.json	hackathon-2025-models/metricas/metricas_*.json	KS, AUC, GINI, config
Predicoes OOT	.parquet	hackathon-2025-models/resultados_modelo/predicoes_oot_*.parquet	num_cpf, safra, score_fpd, decil
Notebook	.ipynb	src/jobs/04_modeling/20260202 - Modelo Final FPD.ipynb	Notebook Databricks (50% sample)
Script OCI	.py	mig_oci/data_science/scripts/modelo_qualificacao.py	Script VM OCI (100% dados)

13.2 Como Reproduzir

Databricks:

```
# Executar o notebook completo
# Path: /Workspace/src/jobs/04_modeling/20260202 - Modelo Final FPD.ipynb
# Configurar SAMPLE_FRACTION = 1.0 para dados completos
```

OCI VM:

```
# Na VM Modelo (via SSH ou Airflow DAG)
python3.11 /opt/modelo-fpd/modelo_qualificacao.py

# Ou local (debug)
python3.11 modelo_qualificacao.py --local
```

13.3 Dependencias

Biblioteca	Versao	Uso
Python	3.11	Runtime
LightGBM	4.x	Modelo
scikit-learn	1.x	Metricas (AUC, ROC)
pandas	2.x	Manipulacao de dados
numpy	1.26.4	Operacoes numericas
pyarrow	14.x	Leitura/escrita Parquet
oci (SDK)	2.x	Acesso Object Storage (OCI VM)

14. Reproducibilidade

14.1 Garantias de Reproducibilidade

Aspecto	Garantia
Seed	42 (fixo em todos os componentes aleatorios)
Split	Temporal por SAFRA (deterministico, sem aleatoriedade)
Features	Selecionadas por IV (deterministico dado os dados)
Early stopping	Baseado em AUC OOT (deterministico dado os dados)
Dados	ABT v6 versionada em Delta Lake (imutavel apos build)

14.2 Variacoes Esperadas

Fator	Variacao Esperada
Reruns com mesmos dados	KS OOT +/- 0.1 p.p. (aleatoriedade do GBDT)
Dados completos vs 50% sample	+0.3 a +0.5 p.p. (mais dados = melhor)

Fator	Variacao Esperada
Novas safras (producao)	KS pode degradar 1-2 p.p./trimestre (drift)

14.3 Validacao pela Banca

Para validar o modelo, a banca pode:

- 1. **Executar o notebook** com `SAMPLE_FRACTION = 1.0` no Databricks
- 2. **Executar o script OCI** na VM dedicada via `modelo_qualificacao.py`
- 3. **Verificar os artefatos** em `hackathon-2025-models/metricas/`
- 4. **Comparar predicoes** com o arquivo OOT (`num_cpf + safra + score_fpd`)

Referencias

Documento	Localizacao
Book de Variaveis (Entregavel B)	banca_final/B00K_VARIAVEIS_COMPORAMENTAIS.md
Estudo Publico-Alvo (Entregavel A)	banca_final/ESTUDO_PUBLICO_ALVO.md
Monitoramento (Entregavel F)	banca_final/PLANO_MONITORAMENTO_MODELO.md
Notebook Databricks	src/jobs/04_modeling/20260202 - Modelo Final FPD.ipynb
Script OCI	mig_oci/data_science/scripts/modelo_qualificacao.py
Book Completo ABT v6	docs/04_gold_rules/B00K_VARIABLES_ABT_V6.md
Artefatos Modelo (guia)	mig_oci/docs/MODELO_ARTEFATOS_GUIDE.md
Troubleshooting Modelo	mig_oci/docs/FASE_8_TROUBLESHOOTING.md