

Plano de Monitoramento do Modelo — Entregável F

Modelo em Produção

Item	Valor
Modelo	LightGBM (gbdt, binary, AUC)
Target	fpd_int — First Payment Default
KS OOT	34.39% (+1.29 p.p. acima do benchmark 33.10%)
AUC OOT	0.7327
GINI OOT	46.54%
Features	261 (selecionadas por IV >= 0.01 de 614 candidatas)
Treino	330.056 registros (safras out/nov/dez 2024)
OOT	205.462 registros (safras fev/mar 2025)
Artefatos	Bucket hackathon-2025-models (PKL, predições, métricas)
Orquestração	Airflow — DAG pipeline_modelo_qualificacao (Start/Stop VM)

1. Métricas-Chave de Monitoramento

1.1 Métricas de Performance do Modelo

Métrica	Descrição	Baseline (Treino Inicial)	Fonte
KS OOT	Kolmogorov-Smirnov — capacidade de separação bom/mau	34.39%	metricas/metricas_{ts}.json → ks_oot

Métrica	Descrição	Baseline (Treino Inicial)	Fonte
AUC OOT	Area Under ROC Curve — discriminação geral	0.7327	metricas/metricas_{ts}.json → auc_oot
GINI OOT	Coeficiente de Gini (2×AUC – 1)	46.54%	metricas/metricas_{ts}.json → gini_oot
Gap vs Benchmark	KS OOT – Benchmark Claro (33.10%)	+1.29 p.p.	metricas/metricas_{ts}.json → gap_benchmark
Overfitting Gap	KS Treino – KS OOT	3.73 p.p.	Calculado: ks_train – ks_oot

1.2 Métricas de Estabilidade

Métrica	Descrição	Threshold Aceitável
PSI (Population Stability Index)	Mede drift na distribuição do score entre períodos	PSI < 0.10 (estável), 0.10–0.25 (atenção), > 0.25 (ação)
Feature Drift	Mudança na distribuição das top features (KL divergence)	KL < 0.05 por feature
N Features Seleccionadas	Quantidade de features com IV >= 0.01	Variação < 10% entre runs (±26 features)
Taxa de Cobertura	% de registros com score válido (não-nulo)	> 95%

1.3 Métricas de Negócio

Métrica	Descrição	Baseline
Taxa FPD Aprovados	% de default entre clientes aprovados pelo modelo	15.26% (taxa 80%)
Swap-out Captura	Maus capturados que o bureau não pegava	69K clientes (FPD 41.8%)
Swap-in Recuperação	Bons recuperados que o bureau recusava	69K clientes (FPD 23.6%)

Métrica	Descrição	Baseline
Redução FPD	Queda na taxa FPD dos aprovados vs bureau puro	-10.8% (taxa 80%)

2. Periodicidade de Monitoramento

CICLO DE MONITORAMENTO
MENSAL (Scoring Batch) ─ Pipeline ETL (21 Data Flow apps) ─ Scoring com PKL existente (train-or-load) ─ Geração de métricas (JSON) + previsões (Parquet) ─ Verificação automática: KS, AUC, PSI, n_features
TRIMESTRAL (Análise Aprofundada) ─ Análise Swap-in/Swap-out atualizada ─ Feature drift (distribuição das top 20 features) ─ Comparação de métricas entre últimos 3 runs ─ Relatório de estabilidade para stakeholders
SEMESTRAL (Retreino Programado) ─ Retreino obrigatório (deletar PKL → treinar do zero) ─ Comparação novo modelo vs modelo anterior ─ Validação de anti-leakage e gates ─ Decisão: promover novo modelo ou rollback
SOB DEMANDA (Eventos de Negócio) ─ Mudança de política da Claro (critérios, planos, público) ─ Nova fonte de dados disponível ─ Incidente operacional (falha no pipeline, dados corrompidos)

Calendário Anual

Mês	Ação	Responsável
Todo mês	Scoring batch + verificação de métricas	Pipeline automático (Airflow)


Mês	Ação	Responsável
Mar, Jun, Set, Dez	Análise trimestral (swap, drift, relatório)	Cientista de dados
Jun, Dez	Retreino programado + validação	Cientista de dados + Líder técnico
Quando necessário	Retreino emergencial (KS caiu > 2 p.p.)	Cientista de dados

3. Critérios Objetivos para Re-treinamento

3.1 Gatilhos Automáticos

#	Critério	Threshold	Ação	Urgência
1	KS OOT cai > 2 p.p.	KS < 32.39%	Retreino emergencial	ALTA
2	KS OOT abaixo do benchmark	KS < 33.10%	Retreino + investigação de causa	ALTA
3	PSI > 0.25	Drift severo na distribuição do score	Investigar + retreinar se confirmado	ALTA
4	Gap Overfitting > 8 p.p.	KS Treino – KS OOT > 8 p.p.	Revisar hiperparâmetros + retreinar	MÉDIA
5	PSI entre 0.10 e 0.25	Drift moderado	Monitorar próximo mês; retreinar se persistir	MÉDIA
6	N features muda > 20%	< 209 ou > 313 features selecionadas	Investigar data drift nas features	MÉDIA
7	6 meses sem retreino	Tempo desde último treino > 180 dias	Retreino programado (governança)	BAIXA

3.2 Fluxo de Decisão de Retreino



3.3 Procedimento de Retreino

```
# 1. Backup do modelo atual (executar LOCAL ou VM)
oci os object copy -bn hackathon-2025-models \
  --source-object-name pkl/modelo_fpd.pkl \
  --destination-bucket hackathon-2025-models \
  --destination-object-name pkl/modelo_fpd_backup_$(date +%Y%m%d).pkl

# 2. Deletar PKL atual para forçar retreino (executar LOCAL ou VM)
oci os object delete -bn hackathon-2025-models \
  --object-name pkl/modelo_fpd.pkl --force

# 3. Trigger do pipeline (executar na VM AIRFLOW, dentro do container)
docker compose exec airflow-scheduler \
  airflow dags trigger pipeline_modelo_qualificacao

# 4. Após conclusão: comparar métricas novo vs anterior (executar LOCAL)
# Baixar JSONs e comparar ks_oout, auc_oout, n_features
```

3.4 Critério de Rollback

Se o novo modelo apresentar **KS OOT inferior ao anterior**:

```
# Restaurar backup (executar LOCAL ou VM)
oci os object copy -bn hackathon-2025-models \
  --source-object-name pkl/modelo_fpd_backup_YYYYMMDD.pkl \
  --destination-bucket hackathon-2025-models \
  --destination-object-name pkl/modelo_fpd.pkl
```

Regra: Só promover novo modelo se $KS_{novo} \geq KS_{anterior} - 0.5$ p.p. (tolerância de 0.5 p.p. para variação amostral).

4. Mecanismos de Alerta para Detecção de Degradação

4.1 Sistema de Semáforo

Semáforo	Condição	Ação	SLA
VERDE	KS OOT $\geq$ 32.39% E PSI $<$ 0.10 E gap_benchmark $\geq$ 0	Operação normal. Nenhuma ação necessária	—

Semáforo	Condição	Ação	SLA
AMARELO	KS OOT entre 31.39% e 32.39% OU PSI entre 0.10 e 0.25 OU gap_benchmark < 0	Investigar causa. Preparar retreino se persistir no próximo mês	15 dias
VERMELHO	KS OOT < 31.39% (queda > 3 p.p.) OU PSI > 0.25 OU KS OOT < benchmark por 2 meses consecutivos	Retreino emergencial. Escalar para líder técnico	5 dias úteis

4.2 Verificação Automatizada Pós-Scoring

O script `modelo_qualificacao.py` já salva métricas em JSON a cada execução. A verificação pode ser implementada como task adicional na DAG do Airflow:

```
# Pseudocódigo – task de verificação pós-scoring
def verificar_metricas(**context):
    """Task Airflow: verifica métricas e gera alerta."""
    import json

    # Carregar métricas do run atual
    metricas = json.load(open(f"metricas/metricas_{timestamp}.json"))

    ks_oot = metricas["ks_oot"]
    gap = metricas["gap_benchmark"]
    n_features = metricas["n_features"]

    # Semáforo
    if ks_oot < 0.3139:
        status = "VERMELHO"
        msg = f"KS OOT = {ks_oot:.2%} – ABAIXO DO LIMIAR CRÍTICO (31.39%)"
    elif ks_oot < 0.3239 or gap < 0:
        status = "AMARELO"
        msg = f"KS OOT = {ks_oot:.2%} – ATENÇÃO (gap benchmark = {gap:+.2%})"
    else:
        status = "VERDE"
        msg = f"KS OOT = {ks_oot:.2%} – MODELO ESTÁVEL (gap = {gap:+.2%})"

    print(f"[{status}] {msg}")

    # Alertas adicionais
    if n_features < 209 or n_features > 313:
        print(f"[AMARELO] N features = {n_features} – variação > 20% do baseline (261)")

    return status
```

4.3 Matriz de Escalação


Nível	Quem é Notificado	Canal	Quando
VERDE	Ninguém (log automático)	Logs Airflow	Todo scoring
AMARELO	Cientista de dados	E-mail / Slack	Quando threshold atingido
VERMELHO	Cientista + Líder técnico + Gerente	E-mail + reunião	Imediatamente
Retreino	Toda equipe de Data Science	Reunião de validação	Pré e pós retreino

4.4 Indicadores de Data Drift

Feature	Método de Detecção	Frequência
score_01_adj (Bureau)	PSI entre safras consecutivas	Mensal
score_02_adj (Bureau)	PSI entre safras consecutivas	Mensal
freq_sos_m1 (Recarga SOS)	Média + desvio padrão vs baseline	Mensal
ticket_medio_m3 (Recarga)	Distribuição (percentis 25/50/75)	Mensal
qtd_pagamentos_m1 (Pagamento)	Cobertura (% não-nulo)	Mensal
pct_aging_90_plus_m1 (Atraso)	Proporção vs baseline	Mensal

Regra de drift por feature: Se PSI de qualquer feature do top 10 superar 0.20 por 2 meses consecutivos, investigar a fonte de dados correspondente.

5. Fluxo Completo de Monitoramento



6. Dashboard de Acompanhamento Mensal

Tabela de KPIs — Exemplo de Acompanhamento

Mês	KS OOT	AUC OOT	PSI	N Features	Gap Benchmark	Semáforo	Ação
Mar/2026	34.39%	0.7327	—	261	+1.29 p.p.	VERDE	Baseline
Abr/2026	—	—	—	—	—	—	Scoring #2
Mai/2026	—	—	—	—	—	—	Scoring #3
Jun/2026	—	—	—	—	—	—	Trimestral + Semestral
Jul/2026	—	—	—	—	—	—	Scoring #5
Ago/2026	—	—	—	—	—	—	Scoring #6
Set/2026	—	—	—	—	—	—	Trimestral
Out/2026	—	—	—	—	—	—	Scoring #8
Nov/2026	—	—	—	—	—	—	Scoring #9
Dez/2026	—	—	—	—	—	—	Trimestral + Semestral

Cálculo do PSI (Population Stability Index)

$$PSI = \sum (\% \text{ score_atual}_i - \% \text{ score_referência}_i) \times \ln(\% \text{ score_atual}_i / \% \text{ score_referência}_i)$$

Onde i são os decis do score. O PSI compara a distribuição do score no mês atual vs o mês de referência (treino).

PSI	Interpretação
< 0.10	Distribuição estável — nenhuma ação
0.10 – 0.25	Mudança moderada — investigar causa
> 0.25	Mudança significativa — retreinar modelo

7. Governança do Modelo

7.1 Papéis e Responsabilidades

Papel	Responsabilidade	Frequência
Pipeline Automático (Airflow)	Executar scoring, gerar métricas, verificação básica	Mensal
Cientista de Dados	Analisar métricas, investigar alertas, executar retreino	Mensal + sob demanda
Líder Técnico	Aprovar retreino, validar novo modelo, escalar problemas	Trimestral + alertas
Gerente / PO	Revisar impacto de negócio, aprovar mudanças de threshold	Trimestral

7.2 Documentação Obrigatória

Cada retreino deve gerar:

Documento	Conteúdo	Armazenamento
Métricas antes/depois	KS, AUC, GINI do modelo antigo vs novo	metrics/ (JSON automático)
Justificativa do retreino	Motivo (queda de KS, drift, programado)	Registro no Airflow (log da DAG)
Lista de features	Features selecionadas no novo modelo	metrics/features_{ts}.txt (automático)
Validação anti-leakage	Confirmação que FPD_INT e FLAG_INSTALACAO não estão nas features	Checklist manual
Decisão de promoção	Aprovação ou rollback, com responsável	Ata de reunião

7.3 Histórico de Versões do Modelo

Versão	Data	KS OOT	Motivo	Status
v1.0	Mar/2026	34.39%	Treino inicial (OCI VM)	Em produção

Versão	Data	KS OOT	Motivo	Status
v0.9	Fev/2026	33.94%	Treino Databricks (referência)	Arquivado
v1.1	Jun/2026 (previsto)	—	Retreino semestral programado	Pendente

7.4 Artefatos de Referência

Artefato	Path	Descrição
Modelo PKL	hackathon-2025-models/pkl/modelo_fpd.pkl	Modelo LightGBM serializado
Métricas JSON	hackathon-2025-models/metricas/metricas_{ts}.json	KS, AUC, GINI, gap, n_features
Predições OOT	hackathon-2025-models/resultados_modelo/predicoes_oot_{ts}.parquet	Score + decil por CPF
Feature list	hackathon-2025-models/metricas/features_{ts}.txt	Features utilizadas
KS incremental	hackathon-2025-models/metricas/ks_incremental_{ts}.json	KS por versão da ABT
Swap analysis	hackathon-2025-models/metricas/swap_analysis_{ts}.json	Impacto de negócio (swap-in/out)

8. Resumo Executivo

Os 4 Pilares do Monitoramento

Pilar	Implementação	Frequência
Métricas-chave	KS, AUC, GINI, PSI, feature drift, gap vs benchmark	Automática (cada scoring)
Periodicidade	Mensal (scoring), trimestral (análise aprofundada), semestral (retreino)	Calendário fixo
CrITÉrios de retreino	KS cai > 2 p.p., PSI > 0.25, 6 meses sem retreino, mudança de política	Thresholds objetivos
Alertas de degradação	Semáforo (verde/amarelo/vermelho), escalação por nível, verificação automatizada	Pós-scoring + notificação

Compromisso de Estabilidade

O modelo atual supera o benchmark em **+1.29 p.p.** (KS 34.39% vs 33.10%). Com o plano de monitoramento descrito, o compromisso é:

- **Manter KS OOT acima de 32.39%** (margem de 2 p.p. antes de retreino emergencial)
- **Manter KS OOT acima do benchmark** (33.10%) — se abaixo por 2 meses, retreino obrigatório
- **Retreino semestral** mesmo sem degradação (boas práticas de governança em crédito)
- **Rastreabilidade completa** — todo run gera métricas JSON, predições Parquet e lista de features

Documento gerado em Março/2026 — Hackathon PodAcademy 2025
Modelo: LightGBM FPD | Infraestrutura: OCI (VM E5.Flex + Airflow + Object Storage)