

Resumo Arquitetura — Texto para Slide

Usar como speaker notes ou caixa de texto ao lado do diagrama de arquitetura.

Arquitetura de Dados — Oracle Cloud Infrastructure

A solução foi implementada integralmente na OCI, seguindo a **Arquitetura Medallion** (Landing → Bronze → Silver → Gold) com infraestrutura gerenciada via **Terraform** (~58 recursos provisionados como código).

Ingestão e Processamento:

6 fontes de dados são processadas por **21 aplicações Spark** no OCI Data Flow, organizadas em 4 grupos paralelos — cada grupo usa famílias de shapes diferentes para evitar competição de quota do **free tier**. O pipeline completo rodou inicialmente em ~2h, mas após ajustes dos shapes e configurações spark, **o pipeline agora roda em ~1h20**.

Armazenamento:

7 buckets no Object Storage segmentados por camada (landing, bronze, silver, gold, models, pipeline-ops, tfstate). Formato Delta Lake com particionamento por safra.

Orquestração:

Airflow 2.8 em Docker Compose numa VM Start/Stop. A DAG principal encadeia os 21 jobs Spark e dispara automaticamente o scoring do modelo via `TriggerDagRunOperator`.

Modelo de Scoring:

VM dedicada (E5.Flex, 2 OCPUs, 32 GB) na subnet privada — ligada sob demanda pelo Airflow, executa o LightGBM (pandas), salva previsões no Object Storage e desliga. KS OOT = 34.39%.

Segurança:

Rede isolada (VCN com 3 subnets: pública, privada-app, privada-dados). Autenticação via Instance Principal (Dynamic Groups) — sem chaves estáticas. Compartments segmentam IAM por papel.

Custo operacional: ~R\$105/mes

Numeros-Chave (para destacar no slide)

Metrica	Valor
Recursos OCI	~58 (todos via Terraform)
Aplicacoes Spark	21 (Data Flow)
Fontes de dados	6
Buckets	7
Pipeline completo	~1h20
Volume armazenado	~40 GB
Custo mensal	~R\$105
KS OOT	34.39% (+1.29 p.p.)

Pontos Para Enfatizar na Fala

- 1. **Infraestrutura como Codigo** — 100% Terraform, reproduçivel, versionado
- 2. **Paralelismo inteligente** — 6 familias de shapes diferentes para rodar 6 jobs simultaneos sem conflito de quota
- 3. **Start/Stop** — VMs ligam apenas quando necessario, custo zero quando paradas
- 4. **Seguranca** — Instance Principal (sem senhas), subnets privadas, IAM por compartment
- 5. **Custo** — \$105