

Preparação da Tabela Analítica de Modelagem (ABT)

Projeto: Hackathon PodAcademy 2025 - Modelo de Risco de Crédito


ABT Final: `hackathon_2025.default.gold_abt_v6_v2` (614 colunas, 3.79M registros)

Índice

1. [Visão Geral do Processo](#)
2. [Fontes de Dados Utilizadas](#)
3. [Estratégia de Integração](#)
4. [Transformações Realizadas](#)
5. [Evolução Incremental da ABT](#)
6. [Tratamento de Valores Ausentes](#)
7. [Validações Implementadas](#)
8. [Resultado Final](#)

1. Visão Geral do Processo

A ABT foi construída utilizando a **Medallion Architecture** (Landing → Bronze → Silver → Gold), com versionamento incremental que permitiu adicionar blocos de features de forma controlada e rastreável.



Princípios de Design

Princípio	Descrição
Versionamento Incremental	Cada versão adiciona um bloco de features, permitindo medir o ganho incremental de KS
Anti-Leakage	Features comportamentais usam apenas dados anteriores à SAFRA
Reprodutibilidade	Metadados de versão e data de build em cada registro
Validação Automática	Gates de qualidade executados a cada build

2. Fontes de Dados Utilizadas

Fonte	Registros	Descrição	Granularidade
Bureau	3.79M	Scores de crédito (Score_01, Score_02) e variáveis target	CPF + SAFRA
Telco	3.79M	Variáveis de comportamento telefônico (var_26 a var_93)	CPF + SAFRA

Fonte	Registros	Descrição	Granularidade
Cadastro	3.79M	Dados demográficos (idade, UF, tempo de relacionamento)	CPF + SAFRA
Recarga	95.2M	Histórico de recargas (valores, frequência, SOS)	CPF + MÊS (evento)
Pagamento	21.8M	Histórico de pagamentos (valores, juros, descontos)	CPF + MÊS (evento)
Atraso	31.6M	Snapshot de faturas em aberto (aging, status)	CPF + MÊS (snapshot)

Descrição das Fontes

Bureau (Spine):

- Fonte principal que define a população da ABT
- Contém `Score_01` e `Score_02` (scores de crédito externos)
- Contém variáveis target: `FPD_INT` (First Payment Default) e `FLAG_INSTALACAO_INT` (aprovação)

Telco:

- 68 variáveis comportamentais (`var_26` a `var_93`)
- Informações sobre uso de telefonia
- Valor sentinela 304 = dado não disponível

Cadastro:

- Dados demográficos e de relacionamento
- Idade, UF, tempo como cliente
- Corrigido em Jan/2026 (substituição de UDF por funções nativas Spark)

Recarga:

- Histórico de todas as recargas do cliente
- Inclui indicador SOS (empréstimo emergencial - indicador de estresse financeiro)
- Requer agregação temporal (evento → cliente-mês)

Pagamento:

- Histórico de pagamentos de faturas

- Inclui valores de juros (indicador de atraso passado) e descontos (negociação)
- Requer agregação temporal

Atraso:

- Snapshot mensal de faturas em aberto
- Distribuição de aging (0-30, 31-60, 61-90, 90+ dias)
- Flags de status crítico (WO, PDD, Fraude)

3. Estratégia de Integração

3.1 Spine (Tabela Base)

O **Bureau** foi utilizado como spine por conter:

- A população completa de clientes elegíveis
- As variáveis target (FPD_INT) e decisão (FLAG_INSTALACAO_INT)
- A granularidade correta (CPF + SAFRA)

3.2 Chave de Junção

Chave: NUM_CPF + SAFRA

Campo	Descrição
NUM_CPF	Identificador único do cliente (11 dígitos)
SAFRA	Mês de referência no formato YYYYMM (ex: 202503)


Garantia de unicidade: Cada combinação CPF + SAFRA aparece exatamente uma vez na ABT (1:1).

3.3 Tipo de JOIN

```
# LEFT JOIN para preservar todos os registros da spine
df_abt = df_spine.join(df_features, on=["num_cpf", "safra"], how="left")
```

Justificativa: LEFT JOIN garante que todos os clientes da população original sejam mantidos, mesmo quando não possuem dados em alguma fonte comportamental.

3.4 Diagrama de Junções



4. Transformações Realizadas

4.1 Camada Bronze → Silver

Transformação	Descrição	Exemplo
Type Casting	Conversão de strings para tipos apropriados	"650" → 650 (int)
Padronização	Nomes de colunas em snake_case	DataNascimento → data_nascimento

Transformação	Descrição	Exemplo
Deduplicação	Remoção de registros duplicados	Via hash MD5 ou row_number()
Tratamento de Sentinelas	Valores especiais convertidos para NULL	0 → NULL + flag_score_missing

Valores Sentinela por Fonte:

Fonte	Valor	Significado	Tratamento
Bureau (Score)	0	Score não calculado	NULL + flag
Telco	304	Dado não disponível	NULL + flag
Recarga	-1, -2, -3	Não aplica, não determinado, não informado	NULL

4.2 Camada Silver → Gold (Feature Engineering)

Recarga Features (60+ variáveis)

```
# =====  
# INDICADOR DE ESTRESSE FINANCEIRO (SOS)  
# =====  
# SOS é um empréstimo emergencial (R$3-20) descontado na próxima recarga  
# Alta frequência de SOS indica dificuldade financeira  
  
freq_sos_m1          # Frequência de uso do SOS no último mês  
pct_sos_sobre_credito_m1  # Proporção SOS/crédito total  
  
# =====  
# PADRÕES TEMPORAIS  
# =====  
dias_medio_entre_recargas_m1  # Regularidade do comportamento  
dias_max_entre_recargas_m1    # Maior intervalo (possível dificuldade)  
  
# =====  
# MÉTRICAS DE VALOR  
# =====  
ticket_medio_m1          # Valor médio por recarga  
coef_variacao_val_m1     # Estabilidade (desvio/média)  
sum_val_credito_m1       # Volume total de crédito  
  
# =====  
# COMPORTAMENTO  
# =====  
pct_recargas_madrugada_m1  # Recargas entre 00h-06h  
pct_recargas_fim_semana_m1  # Recargas sáb/dom  
qtd_canais_distintos_m1    # Diversificação de canais
```

Pagamento Features (50+ variáveis)

```
# =====  
# VOLUME E VALORES  
# =====  
qtd_pagamentos_validos_m1      # Quantidade de pagamentos  
sum_val_pago_m1                 # Valor total pago  
ticket_medio_pag_m1            # Valor médio por pagamento  
  
# =====  
# INDICADORES DE NEGOCIAÇÃO  
# =====  
pct_com_desconto_m1            # % de pagamentos com desconto  
ratio_desconto_pago_m1         # Desconto/Valor pago  
  
# =====  
# INDICADORES DE ATRASO PASSADO  
# =====  
# Juros positivo = cliente pagou com atraso em fatura anterior  
pct_com_juros_m1                # % pagamentos com juros  
sum_val_juros_pos_m1            # Total de juros pagos  
ratio_juros_pago_m1            # Juros/Valor pago
```


Atraso Features (60+ variáveis)

```
# =====
# EXPOSIÇÃO ATUAL
# =====
qtd_faturas_abertas_m1      # Número de faturas em aberto
sum_val_aberto_m1          # Valor total em aberto

# =====
# DISTRIBUIÇÃO DE AGING
# =====
pct_aging_0_30_m1          # % em atraso leve (até 30 dias)
pct_aging_31_60_m1         # % em atraso moderado
pct_aging_61_90_m1         # % em atraso alto
pct_aging_90_plus_m1       # % em atraso severo (90+ dias)

# =====
# FLAGS DE RISCO CRÍTICO
# =====
flag_teve_wo_m1             # Write-off (perda contábil)
flag_teve_pdd_m1           # Provisão para devedores duvidosos
flag_teve_fraude_m1        # Indicação de fraude
flag_teve_aca_m1           # Acordo de cobrança amigável
flag_teve_pccr_m1          # Processo de cobrança/recuperação
```

4.3 Janelas Temporais (Anti-Leakage)

Para features comportamentais (Recarga, Pagamento, Atraso), aplicamos janelas temporais com regra estrita de anti-leakage:

```

# =====
# REGRA DE ANTI-LEAKAGE
# =====
# SAFRA_FEATURE < SAFRA_ABT (apenas dados do passado)
# Nunca usar dados do mesmo mês ou futuro

TEMPORAL_WINDOWS = {
    "m1": 1, # 1 mês anterior
    "m3": 3, # 3 meses anteriores
    "m6": 6 # 6 meses anteriores
}

# Filtro aplicado na agregação
df_filtered = df_joined.filter(
    (F.col("dt_safra_feature") >= F.add_months(F.col("dt_safra"), -num_meses)) &
    (F.col("dt_safra_feature") < F.col("dt_safra")) # ESTRITAMENTE anterior
)

```

Exemplo Visual:

SAFRA ABT: 202503 (Março 2025)

Janela M1: usa apenas 202502 (Fevereiro)

Janela M3: usa 202502, 202501, 202412 (Fev, Jan, Dez)

Janela M6: usa 202502, 202501, 202412, 202411, 202410, 202409

NÃO USA: 202503 (mesmo mês) nem futuros

4.4 Regras de Agregação por Tipo de Coluna

Prefixo da Coluna	Agregação	Justificativa	Exemplo
qtd_*, sum_*	SUM	Acumular totais	sum_val_pago_m3 = soma dos 3 meses
flag_*	MAX	Se ocorreu em qualquer mês	flag_teve_wo_m6 = 1 se teve WO
pct_*, ratio_*, avg_*	AVG	Média do comportamento	pct_com_juros_m6 = média

Prefixo da Coluna	Agregação	Justificativa	Exemplo
max_*	MAX	Pior caso no período	max_aging_m1 = maior aging
min_*	MIN	Melhor caso no período	min_val_pago_m3


```
# Implementação no código
for col in feature_cols:
    if col.startswith(("qtd_", "sum_")):
        agg_exprs.append(F.sum(F.col(col)).alias(f"{col}{sfx}"))
    elif col.startswith("flag_"):
        agg_exprs.append(F.max(F.col(col)).alias(f"{col}{sfx}"))
    elif col.startswith(("pct_", "ratio_", "avg_")):
        agg_exprs.append(F.avg(F.col(col)).alias(f"{col}{sfx}"))
```

5. Evolução Incremental da ABT

5.1 Histórico de Versões

Versão	Fontes Adicionadas	Novas Variáveis	Total Colunas	KS OOT
v1	Bureau (Score_01)	Score_01 + metadados	15	~28%
v2	+ Score_02	Score_02	20	~29%
v3	+ Telco	var_26 a var_93 (68 vars)	95	~30%
v4	+ Cadastro	idade, UF, tempo_relacionamento	185	~31%
v5	+ Recarga	Features M1/M3/M6 (60+ vars)	311	~32%
v6	+ Pagamento + Atraso	Features M1/M3/M6 (170+ vars)	614	33.94%

5.2 Ganho Incremental de KS



6. Tratamento de Valores Ausentes

6.1 Estratégia por Tipo de Feature

```
# =====
# FEATURES DE CONTAGEM/SOMA: Preencher com 0
# =====
# Justificativa: Ausência de dados = 0 ocorrências
for col in df.columns:
    if col.startswith(("qtd_", "sum_", "flag_")):
        df = df.withColumn(col, F.coalesce(F.col(col), F.lit(0)))

# =====
# FEATURES DE PROPORÇÃO/PERCENTUAL: Preencher com 0.0
# =====
for col in df.columns:
    if col.startswith(("pct_", "ratio_")):
        df = df.withColumn(col, F.coalesce(F.col(col), F.lit(0.0)))
```

6.2 Flags de Cobertura

Para cada janela temporal, criamos flags indicando ausência de dados:

```
# Flag indica que cliente não tem dados naquela janela
df = df.withColumn(
    f"flag_sem_recarga_{janela}",
    F.when(
        F.col(f"qtd_meses_dados_rec_{janela}").isNull() |
        (F.col(f"qtd_meses_dados_rec_{janela}") == 0),
        1
    ).otherwise(0)
)

# Variáveis criadas:
# - flag_sem_recarga_m1, flag_sem_recarga_m3, flag_sem_recarga_m6
# - flag_sem_pagamento_m1, flag_sem_pagamento_m3, flag_sem_pagamento_m6
# - flag_sem_atraso_m1, flag_sem_atraso_m3, flag_sem_atraso_m6
```

6.3 Cobertura por Bloco de Features

Bloco	Cobertura M1	Observação
Score_01	98.18%	Muito alta (bureau completo)
Score_02	99.95%	Muito alta
Telco	35.46%	Moderada (nem todos têm dados telco)
Cadastro	35-40%	Corrigido Jan/2026
Recarga	56.12%	Boa cobertura
Pagamento	16.13%	Baixa (clientes novos)
Atraso	21.79%	Baixa (clientes novos)

7. Validações Implementadas (Gates)

7.1 Gates de Qualidade

Cada build da ABT executa validações automáticas que bloqueiam o pipeline em caso de falha:

Gate	Validação	Critério	Ação se Falhar
1	Unicidade	1 registro por NUM_CPF + SAFRA	AssertionError
2	Integridade de Chaves	Sem NULLs em NUM_CPF, SAFRA	AssertionError
3	Anti-Leakage	FPD só observado quando FLAG_INSTALACAO=1	AssertionError
4	Cobertura Score	Score_01 > 90% preenchido	Warning
5	Distribuição Target	FPD ∈ {0, 1}	AssertionError
6	Distribuição Flag	FLAG_INSTALACAO ∈ {0, 1}	AssertionError
7	Cobertura Features	Features M1 > 5% preenchidas	Warning
8	Valores Não-Negativos	Somas e contagens >= 0	Warning

7.2 Implementação

```
def validate_abt_v6(df: DataFrame, count_expected: int) -> bool:
    """Validação para ABT v6."""

    # Gate 1: Unicidade
    count_distinct = df.select("num_cpf", "safra").distinct().count()
    assert count_distinct == df.count(), "Duplicatas encontradas!"

    # Gate 2: Integridade
    nulls_cpf = df.filter(F.col("num_cpf").isNull()).count()
    assert nulls_cpf == 0, "NULLs em NUM_CPF!"

    # Gate 3: Anti-leakage
    leak_check = df.filter(
        (F.col("flag_instalacao_int") == 0) &
        (F.col("fpd_int").isNotNull())
    ).count()
    assert leak_check == 0, "Vazamento de dados detectado!"

    # ... demais gates

    return True
```

8. Resultado Final

8.1 Características da ABT v6

Característica	Valor
Tabela	hackathon_2025.default.gold_abt_v6_v2
Registros	3.795.310
Colunas Totais	614
Features Engineered	~250
Granularidade	NUM_CPF + SAFRA (1:1)

Característica	Valor
Target	fpd_int (First Payment Default)
Período	Out/2024 a Mar/2025

8.2 Distribuição do Target

DISTRIBUIÇÃO DO TARGET
FLAG_INSTALACAO = 1 (Aprovados): 2.633.900 (69.40%)
FLAG_INSTALACAO = 0 (Reprovados): 1.161.410 (30.60%)
Entre os aprovados (FLAG=1):
└─ FPD = 0 (Bom pagador): 2.074.671 (78.77%)
└─ FPD = 1 (Inadimplente): 559.229 (21.23%)

8.3 Performance do Modelo

Métrica	Valor
KS OOT	33.94%
AUC	0.7327
Gini	46.54%
Benchmark	33.10%
Ganho vs Benchmark	+0.84 p.p.

8.4 Metadados Incluídos

Cada registro da ABT contém metadados para rastreabilidade:


```
# Colunas de metadados
abt_version          # "v6.2"
build_date           # Timestamp do build
spine_version         # Versão do spine (bureau)
gold_version          # Versão das features gold
gold_build_date       # Timestamp do build gold
gold_feature_blocks   # "score_01,score_02,telco,cadastro,recarga_v2,pagamento_v2,atraso_v2"
```

Referências

Documento	Caminho
Variable Book (ABT v6)	docs/04_gold_rules/BOOK_VARIABLES_ABT_V6.md
Target Definition	docs/00_project/target_definition.md
ABT v6 Explained	docs/08_team_preparation/technical/gold/09_ABT_V6_EXPLAINED.md
Recarga Features	docs/05_abt_v5_docs/GOLD_RECARGA_FEATURES_V2.md

Documento criado em: Fevereiro 2026
Projeto: Hackathon PodAcademy 2025 - Modelo de Risco de Crédito