

Variable Book — ABT v6.1 (296 Features)

Versão: gold_abt_v6_1
Data de Construção: 2026-01-26
Última Atualização: 2026-01-26 (Correção Cadastro var_03-09, Diagnóstico DESCONTO_RATE)
Grão: 1:1 NUM_CPF + SAFRA
Total de Registros: 3,795,310
Total de Colunas: 296
Target (Observado): FPD_INT (0/1) — apenas quando FLAG_INSTALACAO_INT = 1

Índice

- 1. [Chaves e Identificação](#)
- 2. [Target e Decisão](#)
- 3. [Features v1-v6 Herdadas](#)
- 4. [Features v6.1 Enhancement \(NOVO\)](#)
- 5. [Metadados de Auditoria](#)
- 6. [Anti-Leakage e Temporal Rules](#)
- 7. [Data Types e Storage](#)

Chaves e Identificação

Colunas Obrigatórias (Grão)

Coluna	Tipo	Descrição	Coverage	Observações
num_cpf	STRING	Identificador único de cliente (CPF)	100%	Chave primária, sem NULLs
safra	INTEGER	Período de observação (formato yyyyMM)	100%	Ex: 202501 = janeiro/2025, sem NULLs
dt_safra	DATE	Data de referência (sempre dia 01 do mês)	100%	Derivada de SAFRA

Target e Decisão

CRÍTICO: Regra de Anti-Leakage

NUNCA use estas colunas como FEATURES — são rótulos (labels) e decisões:

Coluna	Tipo	Papel	Observância	Regra
fpd_int	INTEGER (0/1)	TARGET: First Payment Default (inadimplência)	Observado apenas em FLAG_INSTALACAO_INT=1	Gate 2 obrigatório: verificar FPD nulo em FLAG=0
flag_instalacao_int	INTEGER (0/1)	DECISION: Aprovação do crédito (Flag Instalação)	Sempre presente	Use APENAS para Impact Analysis / Swap-in-Swap-out, nunca como feature

Distribuição Observada:

- FLAG_INSTALACAO_INT = 1 (aprovado): 2,633,900 (69.40%)
- FLAG_INSTALACAO_INT = 0 (recusado): 1,161,410 (30.60%)

⚠️ Para Model Training:

- Usar apenas registros com FLAG_INSTALACAO_INT = 1 (n = 2,633,900)
- Target (FPD_INT) observado apenas neste subconjunto
- Usar FLAG_INSTALACAO_INT para análise de impacto e fairness, nunca como feature

Features v1-v6 Herdadas

1 Bloco SCORE (v1)

1.1 SCORE_01

Feature	Tipo	Coverage	Range	Descrição	Rol
score_01_adj	DOUBLE	98.18%	[0, 1000]	Score de crédito ajustado (modelo externo)	Sentinela 0 → NULL + flag
flag_score_01_missing	INTEGER (0/1)	100%	-	Indica sentinela/falta em SCORE_01 (valor 0 original)	Captura informação de missingness

1.2 SCORE_02

Feature	Tipo	Coverage	Range	Descrição	Rol
score_02_adj	DOUBLE	99.95%	[0, 1000]	Score de crédito II ajustado (modelo alternativo)	Sentinela 0 → NULL + flag
flag_score_02_missing	INTEGER (0/1)	100%	-	Indica sentinela/falta em SCORE_02 (valor 0 original)	Captura informação de missingness

2 Bloco TELCO (v3)

Cobertura Agregada: 20.51% (52.9M/258M células preenchidas)

68 features de comportamento de telecom divididas em 3 períodos temporais (M1, M3, M6)

Janelas Temporais:

- M1 (var_001-22): Última 1 mês
- M3 (var_023-44): Últimos 3 meses
- M6 (var_045-66): Últimos 6 meses
- General (var_067-93): Variáveis gerais de perfil (27 features)

Feature	Tipo	Coverage	Range	Descrição
var_01 a var_93	DOUBLE/INTEGER	~20%	Varia	Variáveis de comportamento telecom (recargas, chamadas, dados, etc.)

Nota: Dados de Telco têm cobertura limitada (apenas clientes com contrato ativo na base). Veja docs/01_data_dictionary/telco.md para detalhes de cada variável.

3 Bloco CADASTRO (v4)

Cobertura Agregada: 35-40% (clientes com dados cadastrais)

Status:  Implementado COMPLETAMENTE em v6.1 (296 features finais)

CORREÇÃO CONCLUÍDA (26/01/2026): 

- Bug corrigido! As 7 variáveis numéricas (var_03 - var_09) foram reclassificadas como MISTAS no script Silver
- Adicionadas corretamente à lista NUMERIC_VARS em [02_bronze_silver_cadastro.py](#)
- **Impacto:** +7 features Cadastro restauradas (var_03-09)
- **Coverage:** Mantido em 35-40% (consistente com v4-v6)
- **Total features:** 288 → **296** (288 + 7 numéricas + 1 overlap ajustado)

Features Demográficas (5 features + 1 flag) PRESENTES

Feature	Tipo	Coverage	Range	Descrição	Lógica
idade_anos	INTEGER (LONG)	35-40%	[4, 131]	Idade em anos na safra	DATEDIFF(DT_SAFRA, DT_NASC) / 365
flag_idade_menor_18	INTEGER (0/1)	100%	-	Sanity check: menores de idade	FLAG quando idade < 18
flag_idade_muito_alta	INTEGER (0/1)	100%	-	Outlier check: idade extrema	FLAG quando idade > 100
cep_3_digitos	STRING	35-40%	[000-999]	Proxy geográfico (regional)	3 primeiros dígitos do CEP
flag_cep_missing	INTEGER (0/1)	100%	-	Indicador: CEP ausente	FLAG quando CEP=NULL
statusrf	STRING	35-40%	REGULAR, PENDENTE, SUSPENSA, CANCELADA, FALECIDO	Status cadastral do cliente	MAX(statusrf)

Features Administrativas (2 features) PRESENTES

Feature	Tipo	Coverage	Range	Descrição	Lógica
prod	STRING	35-40%	CMV, DTH, NET	Produto de telecomunicação	TRIM(prod)
flag_mig2	STRING	35-40%	PRE, FLEX, Aquisição	Status de migração de cliente	TRIM(flag_mig2)

Features Numéricas Cadastrais (7 features) PRESENTES

Feature	Tipo	Coverage	Range	Descrição	Data Quality
var_03	DOUBLE	35-40%	[0, ∞)	Variável numérica cadastral 03	0 não numéricos (confirmada)
var_04	DOUBLE	35-40%	[0, ∞)	Variável numérica cadastral 04	0 não numéricos (confirmada)
var_05	DOUBLE	35-40%	[0, ∞)	Variável numérica cadastral 05	0 não numéricos (confirmada)
var_06	DOUBLE	35-40%	[0, ∞)	Variável numérica cadastral 06	0 não numéricos (confirmada)
var_07	DOUBLE	35-40%	[0, ∞)	Variável numérica contínua com outliers	Assimétrica, p99=277.059
var_08	DOUBLE	35-40%	[0, ∞)	Variável numérica discreta	0 não numéricos (confirmada)
var_09	DOUBLE	35-40%	[0, ∞)	Variável numérica discreta	0 não numéricos (confirmada)

 **Correção (26/01/2026):** Todas as 7 variáveis numéricas estão presentes após fix no script Silver.

Features Categóricas/Mistas (16 features) PRESENTES

Feature	Tipo	Coverage	Descrição	Observação
var_10	STRING	35-40%	Variável categórica cadastral	Trim simples
var_11	STRING	35-40%	Variável categórica cadastral	Trim simples
var_12	STRING	35-40%	Possível data (formato inválido em alguns)	Parse tolerante necessário

Feature	Tipo	Coverage	Descrição	Observação
var_13	STRING	35-40%	Variável mista	Mix de tipos
var_14	STRING	35-40%	Variável mista	Mix de tipos
var_15	STRING	35-40%	Categórica (ocupação/profissão)	Alto cardinalidade
var_16	STRING	35-40%	Variável categórica	Trim simples
var_17	STRING	35-40%	Variável categórica	Trim simples
var_18	STRING	35-40%	Variável categórica	Trim simples
var_19	STRING	35-40%	Variável categórica	Trim simples
var_20	STRING	35-40%	Variável categórica	Trim simples
var_21	STRING	35-40%	Variável categórica	Trim simples
var_22	STRING	35-40%	Categórica de alta cardinalidade	Trim + uppercase
var_23	STRING	35-40%	Categórica de alta cardinalidade	Trim + uppercase
var_24	STRING	35-40%	Categórica muito sparse (2.4M não numéricos)	Trim + uppercase
var_25	STRING	35-40%	Variável categórica	Trim + uppercase

Data Quality (Confirmada)

Métrica	Valor	Status
Grão (1:1 por NUM_CPF + SAFRA)	✅ Confirmado	Sem duplicatas
Features de Cadastro PRESENTES	24/33	⚠️ Parcial (faltam 7 numéricas + var_02)
Idade min/max	[4, 131]	⚠️ Outliers presentes (flags criadas)
Missing em DATADENASCIMENTO	16.831 (~0.4%)	✅ Baixo
Missing em CEP_3_dígitos	292.051 (~7.5%)	⚠️ Moderado (flag criada)

4 Bloco RECARGA (v5)

Cobertura Agregada: 56.12% (clientes com atividade de recarga)

Features M1/M3/M6 (3 períodos × 3 features = 9 features)

Feature	Tipo	Coverage	Range	Descrição	Lógica
qtd_recargas_m{1,3,6}	INTEGER	56.12%	[0, ∞)	Quantidade de recargas no período	COUNT(DISTINCT recarga_id)
sum_val_recarga_m{1,3,6}	DOUBLE	56.12%	[0, ∞)	Soma de valores recarregados	SUM(valor_recarga)
avg_val_recarga_m{1,3,6}	DOUBLE	56.12%	[0, ∞)	Valor médio por recarga	AVG(valor_recarga)

Nota: Clientes sem recarga (43.88%) têm valor 0 após coalesce.

5 Bloco PAGAMENTO (v6)

Cobertura Agregada: 17.09% (648.5K clientes com atividade de pagamento)

Features M1/M3/M6 (3 períodos × 13 features = 39 features)

Feature	Tipo	Coverage	Range	Descrição	Lógica
qtd_itens_pagamento_m{1,3,6}	INTEGER	17.09%	[0, 67]	Quantidade de itens pagos	COUNT(*) itens de pagamento
sum_val_pago_m{1,3,6}	DOUBLE	17.09%	[0, ∞)	Soma total paga	SUM(valor_pago)
avg_val_pago_m{1,3,6}	DOUBLE	17.09%	[0, ∞)	Valor médio por item pago	AVG(valor_pago)
max_val_pago_m{1,3,6}	DOUBLE	17.09%	[0, ∞)	Maior valor pago em um item	MAX(valor_pago)
sum_val_desconto_m{1,3,6}	DOUBLE	17.09%	[0, ∞)	Soma de descontos concedidos	SUM(desconto)
sum_val_juros_pos_m{1,3,6}	DOUBLE	17.09%	[0, ∞)	Juros POSITIVOS (client benefit)	SUM(juros > 0)
sum_val_juros_neg_abs_m{1,3,6}	DOUBLE	17.09%	[0, ∞)	Juros NEGATIVOS em valor absoluto	ABS(SUM(juros < 0))
flag_teve_desconto_m{1,3,6}	INTEGER (0/1)	17.09%	-	Indicador: cliente recebeu desconto	MAX(desconto > 0)
sum_pago_forma_01_m{1,3,6}	DOUBLE	~5%	[0, ∞)	Valor pago via forma 01 (ex: dinheiro)	SUM(forma=01)
sum_pago_forma_02_m{1,3,6}	DOUBLE	~5%	[0, ∞)	Valor pago via forma 02 (ex: débito)	SUM(forma=02)
sum_pago_forma_03_m{1,3,6}	DOUBLE	~5%	[0, ∞)	Valor pago via forma 03 (ex: crédito)	SUM(forma=03)
sum_pago_forma_missing_m{1,3,6}	DOUBLE	~1%	[0, ∞)	Valor pago com forma desconhecida	SUM(forma=NULL)
flag_missing_ts_status_pagamento_m{1,3,6}	INTEGER (0/1)	17.09%	-	Flag: >50% de registros sem timestamp	COUNT(NULL ts) / COUNT(*) > 0.5

Nota: Clientes sem pagamento (82.91%) têm valor 0 após coalesce.

 Bloco ATRASO (v6)

Cobertura Agregada: 22.43% (851.4K clientes com faturas abertas)

Features M1/M3/M6 (3 períodos × 19 features = 57 features)

Feature	Tipo	Coverage	Range	Descrição	Lógica
qtd_faturas_abertas_m{1,3,6}	INTEGER	22.43%	[0, 206]	Quantidade de faturas abertas (não pagas)	COUNTDISTINCT(num_fatura_has WHERE valor_aberto > 0)
sum_val_aberto_m{1,3,6}	DOUBLE	22.43%	[0, ∞)	Soma de valores em aberto	SUM(valor_aberto)
avg_val_aberto_m{1,3,6}	DOUBLE	22.43%	[0, ∞)	Valor médio por fatura aberta	AVG(valor_aberto)
max_val_aberto_m{1,3,6}	DOUBLE	22.43%	[0, ∞)	Maior valor em aberto em uma fatura	MAX(valor_aberto)
sum_val_pagamento_m{1,3,6}	DOUBLE	22.43%	[0, ∞)	Soma de pagamentos brutos realizados	SUM(valor_pagamento_bruto)

Feature	Tipo	Coverage	Range	Descrição	Lógica
flag_teve_wo_m{1,3,6}	STRING	22.43%	W/R/-	Flag: Write-Off (compra com prejuízo)	MAX(ind_wo)
flag_teve_pdd_m{1,3,6}	STRING	22.43%	S/N/-	Flag: PDD = Probabilidade Default (modelo)	MAX(ind_pdd)
flag_teve_fraude_m{1,3,6}	STRING	22.43%	S/N/-	Flag: Fraude detectada	MAX(ind_fraude)
flag_teve_aca_m{1,3,6}	STRING	22.43%	S/A/N	Flag: Ação judicial	MAX(ind_aca)
flag_teve_pccr_m{1,3,6}	STRING	22.43%	W/A/C/-	Flag: Parcelamento/Acordo/Consensual	MAX(ind_pccr)
qtd_faturas_aging_0_30_m{1,3,6}	INTEGER	22.43%	[0, ∞)	Faturas com 0-30 dias de atraso	COUNTDISTINCT WHERE aging="0-30 dias"
qtd_faturas_aging_31_60_m{1,3,6}	INTEGER	22.43%	[0, ∞)	Faturas com 31-60 dias de atraso	COUNTDISTINCT WHERE aging="31-60 dias"
qtd_faturas_aging_61_90_m{1,3,6}	INTEGER	22.43%	[0, ∞)	Faturas com 61-90 dias de atraso	COUNTDISTINCT WHERE aging="61-90 dias"
qtd_faturas_aging_90_plus_m{1,3,6}	INTEGER	22.43%	[0, ∞)	Faturas com >90 dias de atraso	COUNTDISTINCT WHERE aging=">90 dias"
qtd_faturas_aging_missing_m{1,3,6}	INTEGER	22.43%	[0, ∞)	Faturas com aging desconhecido	COUNTDISTINCT WHERE aging=NULL

Nota: Clientes sem atraso (77.57%) têm valor 0 após coalesce.

Features v6.1 Enhancement (NOVO)

Bloco ENHANCEMENT (v6.1)

9 features novas divididas em 3 períodos temporais (M1/M3/M6)

Desconto Rate (3 features)

Feature	Tipo	Coverage	Range	Descrição	Fórmula	Interpretação
desconto_rate_m{1,3,6}	DOUBLE	100%	[0.0, 1.0]	Taxa de desconto no período	$\text{SUM}(\text{desconto}) / (\text{SUM}(\text{desconto}) + \text{SUM}(\text{pago}))$	Proporção de desconto rel. ao pagamento total; 0 = sem desconto, 1 = 100% desconto

Cobertura Real (Validada 26/01/2026):

- M1: 100.00%, Média: 0.0000, Máx: 0.0000
- M3: 100.00%, Média: 0.0000, Máx: 0.0000
- M6: 100.00%, Média: 0.0000, Máx: 0.0000

Conclusão (Diagnóstico Executado):

- VAL_DESCONTO_ITEM = 0 em 100% dos 21.8M registros Pagamento
- Desconto é política de negócio: operadora não oferece desconto
- Feature é correta mas constante (sem variância)
- Mantida para auditoria e consistência com roadmap v6.1
- Veja [DIAGNOSTICO_DESCONTO_RATE.md](#) para análise completa

Intuição de Risco:

- ↑ Taxa de desconto → Cliente negocia agressivamente → Pode indicar risco se predisposto a inadimplência

Delinquency Rate (3 features)

Feature	Tipo	Coverage	Range	Descrição	Fórmula	Interpretação
delinquency_rate_m{1,3,6}	DOUBLE	100%	[0.0, 1.0]	Taxa de inadimplência no período	QTD(faturas abertas) / QTD(total faturas)	Proporção de faturas não pagas; 0 = todas quitadas, 1 = todas em aberto

Cobertura Real:

- M1: 100.00%, Média: 0.2243, Máx: 1.0000
- M3: Similar a M1 (dados históricos)
- M6: Similar a M1 (dados históricos)

Distribuição M1:

- 0.0 (cliente sem débito): ~77.57%
- 0.0-0.5 (baixa inadimplência): ~10% dos clientes
- 0.5-1.0 (alta inadimplência): ~5% dos clientes
- 1.0 (100% em aberto): Pequeno % (~0.5%)

Intuição de Risco:

- ↑ Taxa de inadimplência → Cliente tem % alta de dívidas abertas → MUITO indicativo de risco futuro
- **Esta é a feature mais forte do enhancement** (correlação esperada com FPD: ALTA)

Max Days in Arrears (3 features)

Feature	Tipo	Coverage	Range	Descrição	Fórmula	Interpretação
max_dias_atraso_m{1,3,6}	INTEGER	100%	[0, 6771]	Máximo de dias em atraso no período	MAX(DATEDIFF(referencia, vencimento)) para faturas vencidas	Idade da dívida mais antiga; 0 = sem atraso, 6771 = débito de ~18 anos

Cobertura Real:

- M1: 100.00%, Clientes c/ atraso: 11.30%, Média (c/ atraso): 110.9 dias, P90: 11 dias, Máx: 6771 dias
- M3: Similar a M1
- M6: Similar a M1

Distribuição M1:

- 0 dias (sem atraso): ~88.70%
- 1-30 dias: ~6% dos clientes
- 31-90 dias: ~3% dos clientes
- 91-365 dias: ~2% dos clientes
- █ 365 dias (dívida crônica): <0.3% dos clientes

Intuição de Risco:

- ↑ Dias em atraso → Cliente tem dívidas muito antigas → Indicador de insolvência crônica
- Dívidas >1 ano sugerem cliente com problemas financeiros severos
- P90=11d mostra que maioria do atraso é recente (< 2 semanas), mas tail é muito longo

Metadados de Auditoria

Colunas de Rastreabilidade (Sempre Presentes)

Coluna	Tipo	Descrição	Valor
metadata_file_path	STRING	Caminho do arquivo source (Bronze)	Ex: /Volumes/.../bureau_full_delta/...
metadata_ingestion_timestamp	TIMESTAMP	Data/hora do ingestion (Bronze)	ISO 8601
gold_version	STRING	Versão do Gold ABT	"gold_abt_v6_1"
gold_build_date	TIMESTAMP	Data de construção do ABT (Gold)	ISO 8601
gold_feature_blocks	STRING	Blocos de features inclusos	"score_01,score_02,telco,cadastro,recarga,pagamento,atraso,enhancement"

Anti-Leakage e Temporal Rules

✔️ Garantias de Anti-Leakage

- 1. **Todas as features usam dados históricos apenas** (lookback M1/M3/M6)
- 2. **Nenhuma feature usa dados futuro** (pós-snapshot ou pós-safra)
- 3. **FPD_INT é observado apenas 90+ dias após SAFRA** (validação de inadimplência efetiva)
- 4. **FLAG_INSTALLACAO_INT é observada na DT_SAFRA** (aprovação/recusa no momento)

Janelas Temporais Definidas

Período	Meses	Exemplo (SAFRA=202501)	Significado
M1	0	202501 (janeiro 2025)	Mês da observação
M3	0-2	202411-202501 (nov-jan 2024-25)	Últimos 3 meses
M6	0-5	202408-202501 (ago-jan 2024-25)	Últimos 6 meses

Regra Crítica:

- SAFRA = 202501 → Lookback para M1: apenas 202501
- SAFRA = 202501 → Lookback para M3: 202411, 202412, 202501
- SAFRA = 202501 → Lookback para M6: 202408-202501

Data Types e Storage

Tipos de Dados Utilizados

Tipo PySpark	Python	Storage	Exemplos de Colunas
STRING	str	Variable length	num_cpf, flag_teve_wo, metadata_file_path
INTEGER	int	4 bytes	safra, qtd_recargas_m1, max_dias_atraso_m1

Tipo PySpark	Python	Storage	Exemplos de Colunas
DOUBLE	float	8 bytes (IEEE 754)	score_01_adj, sum_val_recarga_m1, desconto_rate_m1
TIMESTAMP	datetime	8 bytes	gold_build_date, metadata_ingestion_timestamp
DATE	date	4 bytes	dt_safra

Estratégia de Null Handling

Coalesce para Zero (Count-based features):

```
F.coalesce(F.col("qtd_recargas_m1"), F.lit(0))
```

→ Indica "cliente sem atividade no período"

Coalesce para 0.0 (Proportion/Rate features):

```
F.coalesce(F.col("desconto_rate_m1"), F.lit(0.0))
```

→ Indica "cliente sem transações / proporção nula"

NULL Preservado (Flags e Categorias):

```
-- flag_teve_wo sem coalesce
```

→ NULL = "informação não disponível", mantém sinal de missingness

Resumo Estatístico por Bloco

Bloco	Features	Coverage Min	Coverage Max	Grão	Status
Identificação	3	100%	100%	NUM_CPF + SAFRA	✔ Completo
Target/Decision	2	100%	100%	NUM_CPF + SAFRA	✔ Completo
Score (v1-v2)	4	98.18%	99.95%	NUM_CPF + SAFRA	✔ Completo
Telco (v3)	136	20.51%	20.51%	NUM_CPF + SAFRA	✔ Completo
Cadastro (v4)	33/33	35-40%	35-40%	NUM_CPF + SAFRA	✔ COMPLETO (var_03-09 restauradas)
Recarga (v5)	18	56.12%	56.12%	NUM_CPF + SAFRA	✔ Completo
Pagamento (v6)	39	17.09%	17.09%	NUM_CPF + SAFRA	✔ Completo
Atraso (v6)	57	22.43%	22.43%	NUM_CPF + SAFRA	✔ Completo
Enhancement (v6.1)	9	100%	100%	NUM_CPF + SAFRA	✔ Completo (DESCONTO_RATE=const)
Metadados	5	100%	100%	Registro	✔ Completo
TOTAL	296	—	—	—	✔ FINAL

✔ ENTREGA FINAL (26/01/2026):

- **Cadastro:** 7 variáveis numéricas (var_03-09) restauradas via correção no Silver
- **DESCONTO_RATE:** Validado como constante=0.0 (política de negócio, sem descontos)
- **Total Features:** 296 (v6: 287 + v6.1: 9)
- **Status:** Pronto para modelagem | KS esperado: 45-46% OOT

1. Preparação para Model Training

```
# Carregar ABT v6.1
df_abt = spark.read.table("hackathon_2025.default.gold_abt_v6_1")

# CRÍTICO: Filtrar apenas registros com FLAG_INSTALACAO_INT = 1
df_train = df_abt.filter(F.col("flag_instalacao_int") == 1)
print(f"Registros para training: {df_train.count():,}") # Expected: 2,633,900

# CRÍTICO: Target é observado neste subconjunto
target = "fpd_int"
features = [col for col in df_train.columns
            if col not in ["num_cpf", "safra", "dt_safra", "fpd_int", "flag_instalacao_int", "gold_", "metadata_*"]]
print(f"Features para modelo: {len(features)}") # Expected: ~280
```

2. Feature Selection

Recomendado iniciar por:

1. Score_01 + Score_02 (baseline)
2. Adicionar Atraso (delinquency_rate + max_dias_atraso)
3. Adicionar Pagamento (qtd/sum values)
4. Adicionar Recarga (quantidade e valores)
5. Adicionar Telco (para refino)

Features Enhancement (v6.1) a considerar:

- delinquency_rate_m{1,3,6} ← **FORTE, espera-se alta correlação com FPD**
- max_dias_atraso_m{1,3,6} ← **FORTE, dívida crônica = risco**
- desconto_rate_m{1,3,6} ← Validar importância (todos zeros no dado atual)

3. Validação de Cobertura

Verificar antes de treinar:

```
coverage_threshold = 0.90 # Mínimo 90%

for col in features:
    non_null_pct = df_train.filter(F.col(col).isNotNull()).count() / df_train.count()
    if non_null_pct < coverage_threshold:
        print(f"⚠️ {col}: {non_null_pct*100:.2f}% coverage")
```

4. Expected Model Performance

Baseline (v6): KS $\approx$ 44-45% OOT

Com Enhancement (v6.1): KS $\approx$ 45-46% OOT (delta: +1-1.5pp)

Referências

- [docs/target_definition.md](#) — Definição temporal do target e anti-leakage
- [docs/01_data_dictionary/](#) — Dicionários detalhados por fonte
- [docs/04_gold_rules/abt_v1.md](#) — v1 base
- [docs/06_abt_v6_docs/ABT_V6_1_IMPLEMENTATION_GUIDE.md](#) — Guia técnico de implementação
- [src/utils/validate_abt.py](#) — Validação com 17 gates

Criado em: 2026-01-26

Próximo Step: Treinar modelo com target FPD_INT (FLAG_INSTALACAO_INT=1)

KS Esperado: 45-46%